

1. 프로젝트 개요

저희는 조선일보, 한겨레, 동아일보, 매일경제, 한국경제, SBS 총 6개 언론사의 기사를 수집하고, 동일한 이슈를 다룬 기사들을 분류한 뒤 언론사별 표현, 강조 내용 및 보도 프레임의 차이를 비교하여 제공하는 뉴스 비교 웹서비스 Prism을 개발하고 있습니다.

현재 기사 수집부터 분석 결과의 웹페이지 제공까지 전반적인 기능을 구현하였으며, 이번 멘토링에서는 다음 세 가지 사항을 중심으로 자문받고자 합니다.

1. Upstage Solar를 활용한 분석 결과의 신뢰성과 일관성 향상
2. 기사 클러스터링의 정확도 평가 및 기준 설정
3. GitHub 기반 협업 구조와 충돌 방지 방식 개선

2. 파이프라인 및 구성

Prism의 기사 수집 및 분석 과정은 다음과 같이 구성되어 있습니다.

단계	처리 과정	주요 내용	산출물
①	RSS 수집	6개 언론사의 언론사별·분야별 RSS 기사 수집	원본 기사 데이터
②	기사 전처리	제목 정제, HTML 제거, RSS 설명 추출, 발행 시각 및 원문 링크 저장	정제된 기사 데이터
③	언론사 내부 클러스터링	TF-IDF와 코사인 유사도를 활용하여 같은 언론사 내 유사 기사 통합	언론사별 기사 클러스터
④	언론사 간 이슈 매칭	언론사별 클러스터 간 유사도를 비교하여 동일 사건 판별	공통 이슈
⑤	Solar LLM 비교 분석	사건 제목, 요약, 공통 사실, 핵심 키워드, 주요 인물, 강조 내용, 표현 방식, 분석 한계 생성	이슈별 비교 분석 결과
⑥	issue.json 생성	분석 결과를 프론트엔드에서 사용할 수 있는 구조로 변환	issue.json
⑦	웹서비스 제공	이슈 목록, 언론사 비교, 키워드 비교, 원문 기사, 발행 시각 제공	Prism 웹페이지

가. 기사 수집

GitHub Actions가 설정된 주기에 따라 실행되며, 각 언론사의 RSS 피드에서 최신 기사를 수집합니다.

수집 대상 언론사는 조선일보, 한겨레, 중앙일보, 매일경제, 한국경제, KBS입니다.

수집하는 정보는 언론사명, 기사 제목, 기사 설명, 원문 링크, 발행 시각이며, 수집 결과는 news.json 파일에 저장됩니다.

나. 언론사별 기사 클러스터링

수집된 기사의 제목과 요약문을 텍스트 데이터로 변환한 후 기사 간 코사인 유사도를 계산하여 동일하거나 유사한 이슈를 다룬 기사들을 묶습니다.

현재는 먼저 각 언론사 내부에서 유사한 기사들을 이슈 단위로 분류한 뒤, 언론사별로 생성된 이슈 묶음 간의 유사도를 다시 비교하여 동일한 사건을 다룬 이슈를 연결하는 방식으로 구현하고 있습니다.

클러스터링 결과는 clusters.json 파일에 저장됩니다.

다. Upstage Solar 기반 기사 분석

동일한 이슈로 분류된 기사 묶음을 Solar에 입력하여 다음 내용을 생성합니다.

이슈 제목과 전체 요약

여러 언론사에서 공통적으로 확인되는 사실

언론사별 핵심 표현과 강조 내용

인용 대상과 맥락의 차이

언론사별 보도 프레임의 차이

분석 과정에서는 기사에 제시되지 않은 사실이나 평가를 임의로 생성하지 않도록 프롬프트에 제한 조건을 설정하고 있습니다.

분석 결과는 issue.json 파일에 저장됩니다.

라. 웹페이지 출력

프론트엔드에서는 생성된 JSON 파일을 불러와 다음과 같은 화면을 제공합니다.

최신 수집 기사 목록

주요 이슈 비교 카드

동일 이슈에 대한 언론사별 기사 비교

공통 사실과 언론사별 강조 내용

개별 기사 원문 링크

마. 자동 업데이트 및 배포

GitHub Actions를 통해 기사 수집과 분석 작업을 자동으로 실행하고 있습니다.

갱신된 JSON 파일이 GitHub 저장소에 반영되면 GitHub Pages를 통해 배포된 웹페이지에도 최신 결과가 적용됩니다.

3. 자문 요청 사항

1. Solar을 지금보다 더 잘 활용하는 방법이 있을까요?

지금은 사건 제목 생성/공통사실 생성/언론사 비교/키워드 추출 정도로 사용합니다. Upstage Solar를 현재보다 더 효과적으로 활용할 수 있는 부분이 있을까요? 심사위원이 봤을 때 Upstage를 잘 활용했다고 느끼려면 어떤 기능이 추가되면 좋을까요?

2. 기사 클러스터링의 정확도 평가 및 임계값 설정

기사 제목과 요약문을 기반으로 한 코사인 유사도 클러스터링에서 적절한 임계값을 설정하고, 정답 데이터가 없는 상황에서도 결과의 정확도를 객관적으로 평가하며 인물명·기관명·발생 시점·핵심 키워드·임베딩 등을 효과적으로 결합하려면 어떤 방법이 적절한지 자문받고자 합니다.

3. GitHub 기반 협업 방식 및 충돌 관리

4인 규모의 팀이 GitHub 브랜치와 Pull Request를 활용해 협업하는 과정에서 공통 파일의 병합 충돌과 작업 중복을 줄이고, 다른 팀원의 최신 변경 사항을 안전하게 반영하기 위해 어떤 브랜치 운영 방식, 파일 분리 기준, 코드 리뷰 및 작업 절차를 적용하는 것이 적절한지 자문받고자 합니다.

4. 실제 서비스로 운용한다면 지금 구조에서 가장 먼저 추가해야 하는 기능은 뭐가 있을까요?
5. 현재 서비스의 차별성이 충분하다고 보시나요? 아니면 개발자 입장에서 하나만 더 넣으면 훨씬 차별화될 기능이 있을까요?
6. 사용자 입장에서 가장 불편한 부분은 어디였나요?
7. 뉴스를 비교 분석하는데에 AI를 사용하고 있는데, 사용자 입장에서는 AI 를 이용하고 있다는 것이 잘 느껴지지 않을 것 같습니다. AI 기능을 직관적으로 사람들이 AI를 사용하고 있다고 체감하게 하려면 어떤 요소를 추가하는 것이 좋나요?