

PRISM

Prism v2 개편·수정 PRD

현재 구현을 보존하면서 Embedding 검색 및 선택형 비교 구조로 전환하는 마이그레이션 명세

Version 1.0 · Change PRD

실제 코딩 시 무엇을 유지하고, 수정하고, 단계적으로 대체하며, 언제 기존 파이프라인을 제거할지
판단하기 위한 실행 문서

작성 기준일: 2026 년 7 월 17 일

문서 구성

번호	항목
1	개편 개요
2	현재 시스템 기준선
3	변경 범위 요약
4	유지·수정·추가·중단 명세
5	목표 아키텍처와 전환 원칙
6	파일별 변경 명세
7	데이터 마이그레이션
8	단계별 개발 계획
9	단계별 검수 기준
10	위험·롤백·운영 전환
11	작업 우선순위와 완료 정의

1. 개편 개요

이 문서는 현재 정상 동작하는 Prism 을 처음부터 다시 만드는 문서가 아니다. 기존 자산을 최대한 재사용하면서 핵심 데이터 파이프라인과 결과 화면을 단계적으로 교체하는 수정 PRD 다.

개편 목표 기존 RSS 수집·프론트엔드·Solar 안정성 로직은 보존하고, TF-IDF 클러스터링 중심 구조를 Embedding 검색 → 언론사별 병렬 분석 → 전체 경향 그룹 → 선택 언론사 비교 구조로 전환한다.

항목	내용
기존 버전	현재 main 브랜치에서 RSS 수집, 클러스터링, Solar 분석, 정적 결과 화면이 동작하는 버전
개편 방식	별도 기능 브랜치에서 단계적 병행 구현 후 신규 파이프라인 검증
중요 원칙	새 기능이 검증되기 전 기존 파일과 데이터 흐름을 삭제하지 않는다.
최종 전환점	홈페이지 핫토픽과 검색·issue 화면이 신규 데이터로 정상 동작하고 회귀 테스트를 통과한 시점

2. 현재 시스템 기준선

현재 구현은 RSS 수집 → TF-IDF 내부 클러스터링 → 언론사 간 클러스터 매칭 → Solar 비교 → issue.json 렌더링 구조다.

```
scripts/generate_news.py
  ↓ data/news.json
scripts/cluster_news.py
  ↓ data/clusters.json
scripts/compare_cluster.py
  ↓ data/matched_clusters.json
scripts/solar_compare.py
  ↓ data/issue.json
app.js + issue.html 렌더링
```

2.1 현재 유지 가치가 높은 자산

- 6개 언론사·3개 카테고리 RSS 수집 코드
- 기사 제목·설명·시각·링크 전처리
- Solar API 연결 및 환경변수 처리
- JSON 파싱, 반환 언론사 검증, 형식 오류 필터링
- 최대 2회 재시도와 성공·실패 로그
- 기존 HTML/CSS/JS 페이지, 헤더, 검색 UI, 카드 스타일, 원문 링크
- Vercel 배포 구조와 Python 내장 HTTP 서버 기반 로컬 화면 테스트

2.2 현재 구조의 교체 대상

- TF-IDF 기반 기사 내부 클러스터링
- 클러스터 간 유사도 매칭을 통한 이슈 생성
- 여러 언론사를 한 번의 Solar 요청으로 비교하는 방식
- 고정 issue.json 을 전제로 한 결과 렌더링
- 언론사 전체를 단순 카드 또는 긴 표로 나열하는 비교 구조

3. 변경 범위 요약

각 자산을 유지, 수정, 추가, 레거시 전환의 네 상태로 관리한다.

상태	의미	대표 대상
유지	구조와 기능을 거의 그대로 사용	generate_news.py, RSS 설정, 기본 페이지·스타일, Solar 오류 처리
수정	현재 코드를 기반으로 입력·출력·호출 단위를 변경	solar_compare.py, app.js, issue.html, 검색·하토픽 연결
추가	현재 없는 신규 기능	Embedding, Vector DB, 대표 기사 선정, 병렬 분석, 경향 그룹, 비교 API, 캐시
레거시 전환	신규 파이프라인 검증 후 핵심 경로에서 제외	cluster_news.py, compare_cluster.py, clusters.json, matched_clusters.json

4. 유지·수정·추가·중단 명세

개편 작업은 파일 삭제보다 의존성 제거를 먼저 수행한다.

4.1 유지

대상	유지 내용	비고
scripts/generate_news.py	6 개 언론사 RSS, 정치·경제·사회, 전처리와 로그	Embedding 입력 품질에 맞춰 필드만 소폭 보강 가능
data/news.json	기사 원천 데이터	article_id 와 updated_at 규칙 보강
HTML/CSS 기본 구조	헤더, 내비게이션, 브랜드 톤, 반응형 카드	결과 화면 정보 구조는 수정
Solar 공통 유틸	API 호출, 환경변수, JSON 파싱, 재시도, 누락 검증	별도 모듈로 분리 권장
배포·로컬 테스트	Vercel, py -m http.server 8000	백엔드 API 테스트는 별도 실행 필요

4.2 수정

대상	현재	개편
검색	search.html 이동과 문자열 처리	Query Embedding → Vector 검색 → 대표 기사 선정
하토픽	matched cluster 기반 이슈	당일 기사 빈도·언론사 수·최신성·의미 유사성 기반 4 개
Solar 분석 단위	이슈 전체 언론사를 한 요청에 입력	언론사별 독립 요청 + 선택 결과 비교
issue.html	고정 비교 카드	공통 사실 → 경향 지도 → 선택 → 시각화 → 대조문·근거
app.js	issue.json fetch 중심	신규 API/JSON, 체크 상태, 선택 비교, 부분 로딩, 캐시 반영
methodology.html	TF-IDF 클러스터링 설명	Embedding 검색과 경향 그룹화의 차이 설명

4.3 추가

신규 요소	역할
generate_embeddings.py	신규 기사 Passage Embedding 생성과 저장
search_articles.py	Query Embedding 과 Vector 검색
select_representative_articles.py	언론사당 기본 1 개·최대 2 개 대표 기사 선정
analyze_publishers.py	동시 3~5 개 제한 병렬 언론사 분석
group_publisher_frames.py	Structured Output 기반 경향 그룹 생성
compare_publishers.py	선택 언론사 최대 4 개 대조 분석
extract_hot_topics.py	핫토픽 4 개 생성과 사전 분석 대상 선정
백엔드 API	핫토픽, 검색, 이슈, 선택 비교 제공
캐시	기사 Embedding, 언론사별 분석, 선택 조합 결과 재사용

4.4 레거시 전환

다음 파일은 신규 파이프라인이 정상 동작하기 전까지 삭제하지 않는다. 먼저 app.js 와 화면에서 의존성을 제거하고, 검수 완료 후 scripts/legacy 와 data/legacy 로 이동한다.

```
scripts/cluster_news.py
scripts/compare_cluster.py
data/clusters.json
data/matched_clusters.json
```

5. 목표 아키텍처와 전환 원칙

새 구조는 기존 파이프라인 옆에 병행 구축하고, 단계별로 화면 연결을 바꾼다.

```
[유지] RSS → news.json
      ↓
[추가] Passage Embedding → Vector DB
      ↓
[추가] Query/Hot Topic → Semantic Search
      ↓
[추가] 언론사별 대표 기사 선정
      ↓
[수정] 언론사별 Solar 제한 병렬 분석
      ↓
[추가] Structured Output 캐시
      ├── 전체 경향 그룹 시각화
      └── 선택 언론사 비교
      ↓
[수정] issue.html / app.js
```

5.1 전환 원칙

- 기존 main 은 항상 실행 가능한 상태를 유지한다.
- 새 기능은 feature/prism-v2-pipeline 브랜치에서 개발한다.
- 단계별 산출물 JSON 을 먼저 검증한 뒤 프론트엔드에 연결한다.
- 언론사별 분석 결과를 재사용하고 선택할 때 기사 원문을 다시 분석하지 않는다.
- 레거시 제거는 신규 경로가 연속 실행되고 검수 기준을 통과한 뒤 수행한다.

6. 파일별 변경 명세

실제 구현 시 파일 단위로 작업 경계를 명확히 한다.

파일	상태	작업
scripts/generate_news.py	유지+소폭 수정	article_id 안정화, updated_at/collected_at, embedding_text 입력 필드 보강
scripts/solar_compare.py	분리·재사용	API 공통 유틸과 비교 전용 로직 분리. 직접 삭제 금지
scripts/cluster_news.py	레거시	신규 검색 검증 후 scripts/legacy 로 이동
scripts/compare_cluster.py	레거시	신규 핫토픽·검색 전환 후 scripts/legacy 로 이동
scripts/generate_embeddings.py	추가	신규·변경 기사만 Passage Embedding 생성
scripts/search_articles.py	추가	Query Embedding, Vector 검색, 필터, 점수 반환
scripts/select_representative_articles.py	추가	언론사별 대표 기사와 선정 이유 출력
scripts/analyze_publishers.py	추가	Semaphore/worker pool 기반 제한 병렬 분석
scripts/group_publisher_frames.py	추가	분석 JSON 유사도와 그룹 라벨 생성
scripts/compare_publishers.py	추가	선택된 Structured Output 의 대조문 생성
data/news.json	유지+확장	기사 원천 데이터
data/hot_topics.json	추가	메인 핫토픽
data/home_issues.json	추가	사전 분석된 홈 결과
data/issue.json	과도기	기존 화면 회귀 테스트용으로 보존, 신규 화면 전환 후 미사용
app.js	대폭 수정	API 연동, 경향 그룹 렌더, 체크 상태, 비교 요청, 부분 로딩
issue.html	대폭 수정	경향 지도와 선택 비교 중심 구조
methodology.html	수정	TF-IDF 핵심 설명을 Embedding/경향 그룹 설명으로 교체

7. 데이터 마이그레이션

새 데이터는 기존 파일을 덮어쓰기보다 새로운 스키마와 캐시 공간에 생성한다.

7.1 마이그레이션 대상

현재	신규	전환 방식
news.json	news.json + Vector DB	기존 기사에 안정적 article_id 를 부여하고 Embedding 생성
matched_clusters.json	hot_topics.json / 검색 결과	직접 변환하지 않고 신규 로직으로 재생성
issue.json	publisher analyses + frame groups + comparison cache	기존 결과를 변환하지 않고 신규 분석으로 생성
정적 파일 fetch	백엔드 API 또는 생성 JSON	단계별로 app.js 연결 전환

7.2 캐시 키

Embedding: article_id + article_updated_at
 언론사 분석: issue_id + publisher_id + sorted(selected_article_ids)
 선택 비교: issue_id + sorted(publisher_ids)

7.3 호환 전략

개발 중에는 기존 issue.json 렌더링과 신규 결과 렌더링을 플래그로 선택할 수 있게 한다. 예: ?mode=legacy 또는 로컬 설정값. 신규 화면이 안정화되면 기본값을 v2 로 전환하고, 마지막에 legacy 경로를 제거한다.

8. 단계별 개발 계획

한 번에 전체 코드를 교체하지 않고 데이터 파이프라인부터 화면까지 8 단계로 진행한다.

단계	목표	주요 작업
0 단계	기준선 보존	main pull, 정상 실행 확인, 화면 캡처, 데이터 백업, 개편 브랜치 생성
1 단계	기사 식별자 정비	news.json 에 안정적 article_id 와 시간 필드 추가. 기존 화면 회귀 확인
2 단계	Embedding 저장	신규 기사 Embedding 생성, Vector DB 저장, 증분 처리 검증
3 단계	의미 검색	검색어 Query Embedding, 관련 기사 반환, 필터·유사도 검증
4 단계	대표 기사 선정	언론사별 기본 1 개·최대 2 개와 선정 이유 출력
5 단계	언론사별 병렬 분석	기존 Solar 유틸 재사용, 동시 3~5 개, Structured Output·재시도
6 단계	경향 그룹·핫토픽	전체 경향 그룹 3~5 개, 핫토픽 4 개와 사전 분석 결과 생성
7 단계	선택 비교 및 UI	최대 4 개 체크, 비교 시각화, 대조문, 근거, 캐시
8 단계	전환·정리	신규 경로 기본화, methodology 수정, 레거시 이동, 최종 회귀 테스트

8.1 권장 Git 흐름

```
git switch main
git pull origin main
git switch -c feature/prism-v2-pipeline

# 단계별로 작은 커밋
git add .
git commit -m "Add article embeddings and vector search"
git push -u origin feature/prism-v2-pipeline
```

9. 단계별 검수 기준

각 단계는 다음 단계로 넘어가기 전에 독립적으로 실행·검증 가능해야 한다.

단계	검수 영역	완료 기준
0	기준선	현재 메인·이슈·검색 페이지와 6 개 RSS 수집이 정상 동작한다.
1	기사 ID	재실행해도 동일 기사 ID 가 바뀌지 않고 기존 app.js 가 깨지지 않는다.
2	Embedding	신규 기사만 처리되며 같은 기사는 재호출되지 않는다.
3	검색	대표 검색어 5 개에서 관련 기사가 상위에 나오고 다른 이슈 혼입이 제한된다.
4	선정	언론사별 1 개가 기본이며 2 개는 명확한 다른 가치가 있을 때만 선택된다.
5	분석	각 언론사 JSON 이 스키마를 통과하고 한 실패가 전체 실패로 이어지지 않는다.
6	그룹	3~5 개 그룹이 생성되고 이름이 고정 성향을 단정하지 않는다.
7	UI	전체 경향을 먼저 보고 최대 4 개 선택 비교가 가능하며 모바일에서 긴 표가 없다.
8	전환	신규 기본 경로가 전체 회귀 테스트를 통과하고 레거시 없이 사용자 흐름이 완결된다.

9.1 핵심 인수 테스트

- 핫토픽을 클릭하면 전체 경향 그룹이 먼저 표시된다.
- 언론사를 2~4 개 체크하면 선택한 언론사만 비교된다.
- 선택을 바꿔도 언론사별 기사 분석은 다시 실행되지 않는다.
- 대조문에는 각 언론사의 근거 표현이 연결된다.
- 두 언론사가 유사할 때 차이를 억지로 만들지 않는다.
- 한 언론사 요청이 실패해도 나머지 그룹과 비교 결과가 가능한 범위에서 표시된다.

10. 위험·롤백·운영 전환

개편 중 서비스 중단을 피하기 위해 레거시 경로와 신규 경로를 일정 기간 병행한다.

위험	예방	롤백
Vector 검색 품질 저하	대표 쿼리 테스트셋과 필터·임계값 조정	legacy issue.json 화면으로 전환
Solar 호출 급증	동시성 제한, 캐시, 사전 분석	검색 결과만 제공하고 상세 비교 일시 제한

위험	예방	롤백
JSON 스키마 실패	파싱 검증과 재시도, 실패 언론사 격리	정상 언론사 결과만 표시
프론트엔드 회귀	기능 플래그와 단계별 화면 테스트	legacy mode 기본값 복원
API Key 노출	백엔드 환경변수, .gitignore, ZIP 검사	키 폐기·재발급 및 노출 커밋 정리

10.1 레거시 제거 조건

- 신규 핫토픽 4 개가 자동 생성되고 메인에서 정상 표시된다.
- 검색어로 관련 기사와 대표 언론사가 안정적으로 반환된다.
- 언론사별 분석 누락과 형식 오류가 허용 수준 이내다.
- 경향 그룹과 선택 비교 화면이 PC·모바일에서 정상 동작한다.
- 최소 3 개 이슈에 대한 end-to-end 테스트를 통과한다.
- 롤백용 Git 태그 또는 main 커밋이 확보되어 있다.

11. 작업 우선순위와 완료 정의

기능을 빠르게 보여주기보다 데이터 기반을 먼저 안정화하고, 마지막에 UI 를 연결한다.

우선순위	작업	이유
P0	기사 ID, Embedding, Vector 검색	모든 신규 기능의 기반
P0	언론사별 Structured Output 과 제한 병렬	비용·안정성·확장성 핵심
P1	대표 기사 선정과 캐시	분석 품질과 호출량 제어
P1	경향 그룹과 선택 비교	Prism v2 의 핵심 사용자 가치
P1	issue.html/app.js 개편	사용자 경험 구현
P2	후속 질문, 저장·공유, 고급 시각화	핵심 전환 완료 후 확장

11.1 Definition of Done

- 기존 RSS 수집 기능이 유지된다.
- TF-IDF 클러스터링 없이 핫토픽과 검색 결과를 생성할 수 있다.
- 언론사별 분석은 독립·제한 병렬로 실행된다.
- 전체 언론사의 보도 경향이 3~5 개 그룹으로 시각화된다.
- 사용자가 최대 4 개 언론사를 선택해 대조문과 근거를 확인할 수 있다.
- 동일 기사와 동일 조합은 캐시로 재사용된다.
- 기존 레거시 파일은 의존성 제거 후 별도 위치에 보존되거나 명시적으로 폐기된다.
- methodology.html 과 문서가 실제 구현과 일치한다.

실행 판단 기준 전체 PRD 는 “어디로 갈지”를 설명하고, 이 수정 PRD 는 “현재 코드에서 어떤 순서로 어떻게 갈지”를 설명한다. 실제 코딩 중에는 수정 PRD 를 작업 체크리스트로 사용한다.